ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N.º 1

[Consolidación de reportes de ventas (CSV, JSON y Excel)

Tópico Lectura de archivos de datos en Python y R del PEA · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	León Camacho Ricardo Leandro — usuario de GitHub: Rick1751
Docente	Christian Suárez
Período académico	2026-B
Fecha de entrega	19/09/2026
Repositorio (fork)	https://github.com/Rick1751/IDSD422-lab1-lectura-datos

1. Introducción

RetailAndina S.A. es una cadena ecuatoriana de tiendas de consumo masivo con sucursales en Quito, Guayaquil y Cuenca. Cada semana, su equipo de Business Intelligence recibe el reporte de ventas en tres formatos distintos, porque cada uno sale de un sistema independiente: el ERP de sucursales entrega un archivo CSV, la plataforma de fidelización responde con un JSON desde su servicio web y Finanzas prepara un consolidado en Excel.

2. Objetivos

Objetivo general. Verificar que los reportes de ventas semanales de RetailAndina S.A., recibidos en CSV, JSON y Excel, contienen la misma información, leyéndolos y describiendo su estructura en Python y en R.

Objetivos específicos:

(1) Leer los archivos ventas.csv, ventas.json y ventas.xlsx en Python (pandas) y en R (readr, jsonlite y readxl).

(2) Verificar las dimensiones (filas y columnas) y el tipo de dato de cada variable en los tres formatos.

(3) Comparar los tres archivos para determinar si coinciden en contenido y reportar las diferencias encontradas.

(4) Calcular los indicadores iniciales que pide la gerencia (venta promedio, ticket promedio, sucursal y región destacadas) e interpretarlos.

3. Desarrollo de la práctica

3.1 Entorno y datos

Trabajé con Python 3 y pandas en colab en los laboratorios de la universidad ademas con un entorno local de mamba para el tema local y la implementacion del github de mi computadora para aprender tambien sobre entornos portables y uno dedicado y con R los siguientes 4 paquetes (readr, jsonlite, readxl) en Posit Cloud / local de igual manera en local con R studio para verificar y tener un entorno propio. Clono mi fork y ejecuto cada script desde la raíz del repositorio con rutas relativas (data/ventas.csv, data/ventas.json y data/ventas.xlsx), de modo que cualquiera pueda reproducir el trabajo, con ciertos matices de ver las rutas que se usaron, en realidad las que estan en el repo estan cambiadas para un sistema linux, ya que estas subes manejan estos contenedores, si hacemos en windows es mas complejo manejar las rutas relativas de los mismos. Los datos son el reporte semanal de cinco sucursales: sucursal, region, ventas y clientes.

3.2 Lectura del CSV (Python)

Leí el archivo con pd.read_csv y revisé sus dimensiones y primeras filas (script leer_csv.py).

```
import pandas as pd
df = pd.read_csv("data/ventas.csv")   # ruta relativa a la raíz del repo
print(df.shape)                        # (filas, columnas)
print(df.head())                       # primeras filas
```

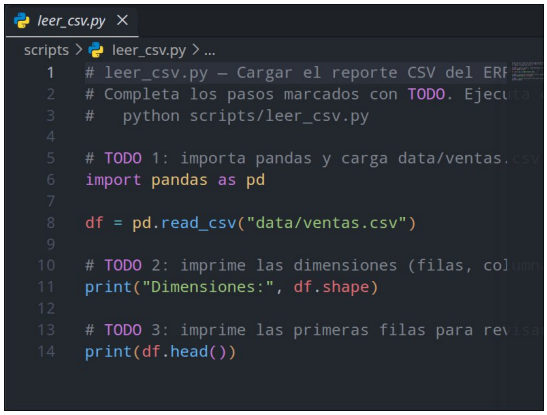


Figura 1. *Lectura del CSV en Python: shape (5, 4) y primeras filas.*

El CSV tiene 5 filas (una por sucursal) y 4 columnas: sucursal, region, ventas y clientes.

3.3 Lectura del JSON (Python)

El JSON no llega como tabla sino como una lista de diccionarios. Lo cargué con json.load y lo aplané con pd.json_normalize (leer_json.py).

```
import json
with open("data/ventas.json", encoding="utf-8") as f:
    datos = json.load(f)        # lista de diccionarios
df = pd.json_normalize(datos)   # se convierte en tabla (DataFrame)
```



Figura 2. *JSON aplanado en Python: shape (5, 4), igual que el CSV.*

3.4 Lectura del Excel (Python)

Indiqué la hoja con sheet_name="ventas", que es la única hoja del libro (leer_excel.py).

```
df = pd.read_excel("data/ventas.xlsx", sheet_name="ventas")
```

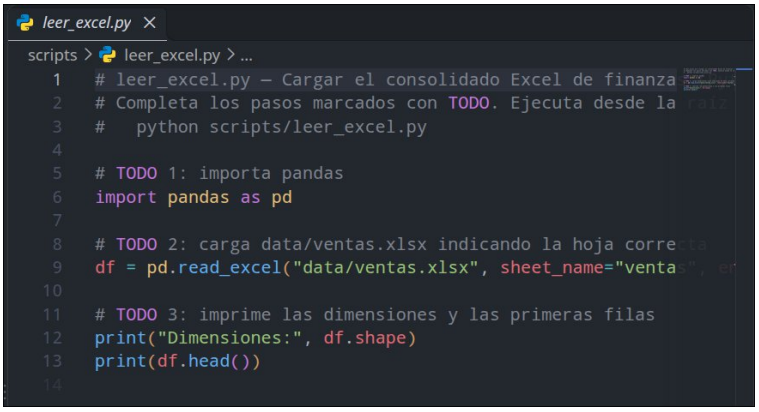


Figura 3. *Excel leído en Python: shape (5, 4) y primeras filas.*

Los tres formatos produjeron la misma tabla de 5 filas y 4 columnas, con valores idénticos:

Formato	Lectura (Python)	Filas	Columnas	Igual al CSV
CSV	pd.read_csv	5	4	—
JSON	json.load + json_normalize	5	4	Sí
Excel	pd.read_excel (hoja ventas)	5	4	Sí

3.5 Inspección de tipos e indicadores (Python)

En inspeccion.py revisé los tipos con df.dtypes, creé la columna derivada ticket = ventas / clientes y calculé los indicadores. El ticket promedio lo calculé como ventas totales ÷ clientes totales (promedio ponderado), no como el promedio de los tickets de cada sucursal.

```
print(df.dtypes)
df["ticket"] = df["ventas"] / df["clientes"]
ticket_promedio = df["ventas"].sum() / df["clientes"].sum()   # ponderado
ventas_region = df.groupby("region")["ventas"].sum()
```

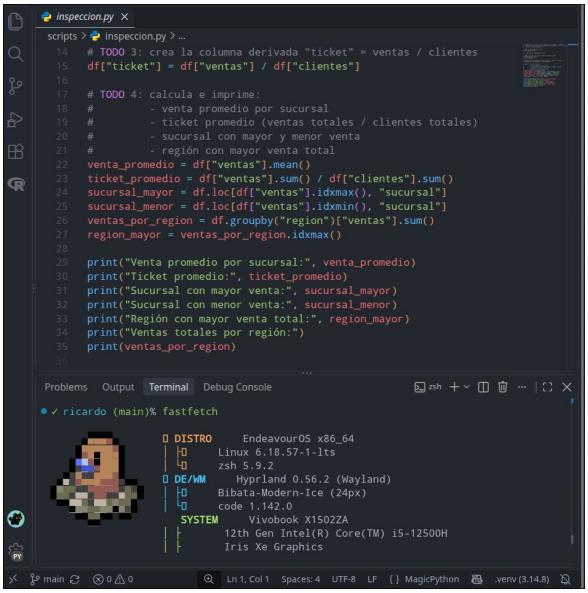


Figura 4. *Tipos de columna e indicadores calculados en Python (inspeccion.py).*

Variable	Python	R	Interpretación
ventas	int64	numeric	Importe numérico: se puede sumar y promediar.
clientes	int64	numeric	Conteo numérico.
sucursal	str	character	Texto: nombre de la sucursal.
region	str	character	Texto categórico (Sierra / Costa).

Los tipos son los esperados. Si ventas hubiera llegado como texto (por ejemplo, con un símbolo $ o una coma), habría indicado un dato sucio y los promedios habrían fallado.

Indicador	Valor
Venta promedio por sucursal	12008
Ticket promedio (60040 ventas ÷ 1577 clientes)	38.07
Sucursal con mayor venta	Guayaquil Centro (15200)
Sucursal con menor venta	Cuenca (8540)
Región con mayor venta total	Sierra (30860; Costa: 29180)

Sierra suma más porque tiene tres sucursales y Costa solo dos; por sucursal, Costa vende más (14590 de promedio frente a 10287 de Sierra).

3.6 Lectura e inspección en R

Repetí el proceso en R con readr::read_csv, jsonlite::fromJSON y readxl::read_excel(sheet = "ventas"), y revisé los tipos con str() (scripts leer_csv.R, leer_json.R, leer_excel.R e inspeccion.R).

```
df <- read_csv("data/ventas.csv", show_col_types = FALSE)
df_json  <- as.data.frame(fromJSON("data/ventas.json"))
df_excel <- read_excel("data/ventas.xlsx", sheet = "ventas")
str(df)   # ventas y clientes: numeric; sucursal y region: character
```



Figura 5. *Lectura de los tres archivos en R: dimensiones y primeras filas.*

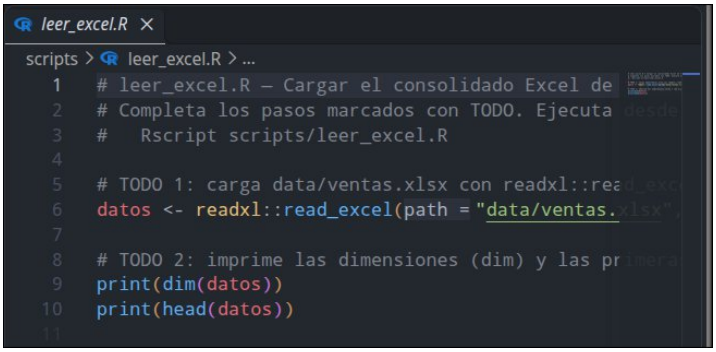


Figura 6. *Estructura (str) e indicadores en R (inspeccion.R).*

En R, region llegó como `character` y no como factor, y los resultados coinciden con los de Python.

3.7 Problemas encontrados y cómo los resolví

- **Rutas absolutas.** Al inicio usé rutas de mi computador (C:\Users\...), que no funcionan en otra máquina. Las cambié por rutas relativas a la raíz del repositorio.
- **object frente a str.** En Colab las columnas de texto salían como object y en mi equipo como str. Es la misma lectura con distinta versión de pandas; el contenido no cambia.
- **Lectura del Excel.** Con el motor calamine necesitaba instalar un paquete adicional; usé el motor por defecto (openpyxl) y no hizo falta instalar nada más.

4. ¿Qué aprendí con esta práctica?

Principalmente a manejar distintos objetos y entender no solo a programar directamente, sino a entender la parte tecnica de la creación de codigo, a arreglar manejar algunos entornos con sus dependencias en mi sistema personal linux, usar las rutas en windows de las Pc del laboratorio, configurar el colab y ver que es un contendor de linux muy livianito, que incluso se puede configurar un flujo de git directo sin iniciar en windows de manera no segura, asimismo, aprender a ver el inicio del flujo del ciclo de los datos en la normalizacion y su posterior analisis, lo que lleva a tomar mejores decisiones de negocio e incluso hacer análisis de cualquier cosa en base a mi conocimiento o incluso aprender a inferenciar un poco mas.

5. Conclusiones

1. Los tres reportes (CSV, JSON y Excel) se leyeron en Python y en R y dieron la misma tabla: 5 filas y 4 columnas (sucursal, region, ventas y clientes) con valores idénticos. La estructura interna distinta (texto, anidada, binaria) no cambió el contenido, aunque el JSON requirió aplanarse y el Excel necesitó indicar la hoja ventas.
2. Los tipos son los esperados: ventas y clientes son numéricos (int64 en Python, numeric en R) y sucursal y region son texto. Esto permite calcular sin conversiones previas.
3. Con los datos consolidados, la venta promedio por sucursal fue 12008 y el ticket promedio 38.07. Guayaquil Centro lideró con 15200 y Cuenca tuvo la menor venta con 8540. Sierra tuvo la mayor venta total (30860 frente a 29180 de Costa), en parte porque tiene una sucursal más.

Respuesta a la gerencia. Los tres reportes contienen la misma información, así que se puede trabajar con cualquiera. Recomiendo estandarizar el intercambio en CSV (el más simple de leer) y mantener una validación automática de tipos y dimensiones entre fuentes. **Alcance:** son 5 sucursales de una sola semana; estos resultados describen ese período y no permiten proyectar tendencias.

6. Bibliografía

Bruce, P., Bruce, A. y Gedeck, P. (2020). Practical Statistics for Data Scientists (2.ª ed.). O'Reilly.

pandas development team. (2026). pandas.read_csv. https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html

pandas development team. (2026). pandas.json_normalize. https://pandas.pydata.org/docs/reference/api/pandas.json_normalize.html

pandas development team. (2026). pandas.read_excel. https://pandas.pydata.org/docs/reference/api/pandas.read_excel.html

Wickham, H., Hester, J. y Bryan, J. (2026). readr: Read rectangular text data (read_csv). https://readr.tidyverse.org/reference/read_delim.html

Ooms, J. (2026). jsonlite: A simple and robust JSON parser and generator for R. https://cran.r-project.org/package=jsonlite

Wickham, H. y Bryan, J. (2026). readxl: Read Excel files (read_excel). https://readxl.tidyverse.org/reference/read_excel.html

Escuela Politécnica Nacional. (2026). Laboratorio 1: Consolidación de reportes de ventas [datos del caso RetailAndina S.A.]. IDSD422. https://github.com/christian-suarez1979/IDSD422-lab1-lectura-datos

Declaración de uso de IA. Usé github copilot para hacer la descripcion de algunos commits y subirlos rapidamente en el laboratorio, ademas para la correccion de errores en el path al pasar en algunos entornos como lo es el uso de r¨" en windows ya que el colab ofrece mas flexibilidad para entornos linux ya que es un contendor del mismo.